

朱礼鹏

男 | 28 岁

19506416522 | zhulipengnxi@163.com

求职意向: 后端开发 / Agent 开发

GitHub 主页: <https://github.com/Zhu1Li>

教育经历

吉林大学	软件工程	硕士	2021.10 - 2024.06
曲阜师范大学	物理学	本科	2016.09 - 2021.06

专业技能

- **Java:** 熟练掌握 Java 核心技术, 包括集合框架、并发编程(JUC 、线程池、锁机制)、反射机制, 理解 JVM 内存模型与 GC 机制。
- **框架:** 熟练使用 Spring Boot / Spring Cloud Alibaba 进行微服务开发, 理解 Bean 生命周期、自动装配、 AOP 原理。
- **数据库:** 熟悉 MySQL 数据库, 理解事务管理、索引、锁等数据库操作。
- **Redis:** 熟练使用 Redis, 掌握多种数据结构应用场景, 具备缓存架构设计 (多级缓存、防穿透/击穿/雪崩) 和分布式锁实战经验。
- **中间件:** 熟悉 Kafka 消息中间件, 掌握消息可靠投递、幂等消费、延迟队列设计。
- **Agent:** 熟练使用 AI Coding 工具增效, 熟悉 Agent 开发相关理念。具备 Agent 架构设计、Function Calling、 RAG、 MCP 协议集成经验。

工作经历

浪潮云信息技术股份公司	软件开发工程师	2024.07 - 2026.04
所在部门: 海若产品部, 主要业务方向为政府部门、传统行业等的数字化转型。		

主要工作内容:

- 负责政务类 (ToG) 数字化项目后端开发与系统设计。
- 基于智能体编排平台 (Dify 二开平台) 设计并实施 Agentic Workflow 解决方案, 并与客户业务系统进行集成。
- 参与系统架构设计评审与基础架构优化 (缓存、消息队列、延迟任务等)。

项目经历

政务办公智能 Agent 平台	后端开发 / Workflow 编排	2025.12 – 2026.02
-----------------	--------------------	-------------------

- **项目简介:** 面向省内政务的政策问答与检索系统, 对外提供民生政策与办事指南问答, 对内集成公文检索、应急管理驾驶舱、OA 协同、定时推送等能力。主力客户知识库含 4 万+份政策文档, 分块后 35 万+片段, 按密级和部门权限受控检索, 覆盖多密级, 内外隔离。
- **技术栈:** Python, LangChain, ES(BM25), Milvus, bge-m3, bge-reranker-v2-m3, Dify(公司二开编排平台), Redis, Prometheus + Grafana, Java·Spring Boot(业务系统集成)
- **负责功能:**
 1. **数据预处理与入库:** 负责多源公文/政策文档的清洗与分块, 针对政务公文强结构性设计分层分块策略 (结构优先+父子分块), 解决长条款跨块漏检, 元数据带部门 / 地区 / 年份 / 文种, 多源公文按文号去重后增量写入 ES 与 Milvus。
 2. **混合召回链路的设计与调优:** 设计 ES(BM25)+Milvus(向量)双路召回, 应用层自实现 RRF 融合; 按 query 类型动态路由两路权重 (专名/文号抬 BM25、口语化抬向量), 并沉淀机/政策专名词典做简称→全称扩展补强专名召回; 融合候选再经 bge-reranker 交叉编码精排。
 3. **低召回兜底策略:** 根据置信度代理信号判定低召回, 触发“锁定地区硬过滤 + LLM 查询改写 → 二次检索”的自纠正闭环; 持续低置信度以拒答兜底, 无据不答, 控制政务场景幻觉风险。

4. **Agent 编排与低召回兜底**: 设计意图识别与路由分流, 将请求分诊到 政策问答 / 数据问数 / 办事指南 等分支按意图调用工具; 检索 /Agent 服务以 **Spring Boot 封装 REST** 供业务系统集成。
5. **评测体系与效果**: 基于甲方 12345 热线工单与窗口高频咨询构建真实市民 query 评测集, chunk 级 golden, 以 badcase 驱动逐层调优并量化每层策略的收益边界; 检索 **Recall@5** 由 **56% 提升至 90%**、问答 **hits@3** 约 **87%**、rerank 首位命中率(**MRR@10**) **0.46→0.81**; 并通过候选裁剪将精排 **P95** 延迟降低一半以上。

上善·海若水利大模型平台

后端开发 / workflow 编排

2025.06-2025.10

- **项目简介**: “上善·海若”水利大模型平台是水利部信息中心指导、浪潮云打造的首个全国化生产级水利行业大模型簇。平台深度融合数字孪生知识图谱与 DeepSeek 等大模型能力, 构建了覆盖“数据-知识-决策”全链条的智能体系。聚焦防洪“四预”(预报、预警、预演、预案)、水资源调度、水库智能管理等核心业务, 为省市级水利部门提供可解释、可落地的 AI 辅助决策支撑, 推动水利管理从“经验驱动”向“智能驱动”转变。
- **技术栈**: Python, LangChain / LangGraph, Redis (会话状态·checkpointing), Elasticsearch, OCR, LLM Fine-tuning, Java·Spring Boot (业务系统集成)
- **负责功能**:
 1. 防洪调度 Agent 构建: 设计“水文数据采集→产汇流模型预测→洪水演进模拟→LLM 风险研判与调度建议→人工确认”的多步 Agent 编排; 针对闸门启闭、蓄滞洪区启用等真实世界写操作, 设计强制双人确认环节, 防止模型自主执行高风险动作。
 2. 预案/公文自动生成: 接入水文监测数据与预报结果, 由 LLM 按模板结构自动生成防汛预警通报、应急预案、水文统计公报等公文, 关键数字从上游算法结果中提取填充 (非 LLM 生成), 控制数值幻觉风险。
 3. 异构算法工具化: 将合作单位提供的产汇流模型、洪水演进等异构算法 (输入输出格式/单位不统一) 封装为 MCP 标准化 Tool Schema, 加适配层做单位换算与格式转换; 长耗时算法 (洪水演进 ~分钟级) 设计异步提交-轮询-超时兜底编排模式。
 4. 领域语料工程与模型微调: 针对水利专业术语覆盖不足, 主导 PDF 扫描件 OCR→清洗→语料构建 (时长约 2 个月), 用于领域大模型微调。

某市文旅通——全域文旅公共服务平台

后端开发

2024.12 - 2025.05

- **项目简介**: 某市文旅局主导建设的全域文旅公共服务平台, 整合全市 25+景区与 10+剧院资源。内置惠民政策规则, 按游客户籍地自动匹配对口支援免票、消费券核销等权益, 财政补贴全程可溯。提供客流数据驾驶舱, 支撑节假日应急调度与市场治理。通过智能客服实现精准应答与个性化服务, 兼顾系统性能与用户体验。
- **技术栈**: Spring Cloud Alibaba, SpringBoot, MySQL, Redis, Redisson, Kafka, Lua, Elasticsearch, Caffeine, Prometheus + Grafana
- **负责功能**:
 1. 设计 **Caffeine + Redis** 多级缓存, 分层抗压: 布隆过滤器+空值缓存防穿透; 热点数据按业务类型选用分布式锁+双重检查或逻辑过期+异步重建防击穿; 随机 TTL 错峰 + Redis 集群保障高可用防雪崩, 并采用 **读写锁 + Cache Aside** 策略保证缓存最终一致性。
 2. 主导购票核心链路设计, 将余票扣减前移到 **Redis** 层面执行, 通过 **Lua** 脚本实现无锁化库存校验与扣减的原子执行, 平均响应耗时从 324ms 降低至 87ms。配合 **Kafka** 异步解耦订单入库, 兜底**对账补偿**任务扫描 Redis / DB 差异自动修复, 保证数据最终一致性。
 3. 基于 **Redisson** 延迟队列 + 分片拆分思想 + 线程池并行消费设计高性能延迟队列, 将延迟任务分散到多个分片队列并行处理, 大幅提升延迟任务吞吐能力。

4. 设计订单表基因法分片路由，将用户 ID 后 6 位基因片段嵌入订单号，使订单号与用户 ID 均能定位到同一分片，避免全库广播查询。
5. 设计惠民权益体系：购票人绑定时异步实名核验，结合详情页购票人预载缓存，下单按标签实时计算优惠价；每笔减免生成流水入对账，支撑财政补贴溯源。

Li Code——自实现 Coding Agent

后端开发/Agent 应用

2026.03 - 2026.06

- **项目简介：**离职后自己学习 Claude Code 设计思想，脱离 langchain 等开发框架，仅基于模型 API 协议与 MCP SDK 实现的轻量级终端 Coding Agent 项目，基于 ReAct 和 Plan Mode 双模式驱动 LLM 自主完成编程任务。支持 Anthropic / OpenAI 双协议，支持 MCP 工具扩展、Skill 技能包、跨会话记忆等机制。
- **技术栈：**Java, Anthropic / OpenAI SDK, MCP, ReAct, Multi-Agent
- **负责功能：**
 1. 实现 Agent 核心决策循环，支持两种 Anthropic / OpenAI 两种协议模型的接入与使用。工具调用结果自动回灌并触发下一轮推理，配合 **max_tokens 恢复机制**，确保长任务不因输出截断而中断。
 2. 实现 **MCP 工具延迟加载**，百级工具场景下工具描述 Token 占用减少 85%，避免上下文窗口被工具定义挤占。
 3. 设计**渐进式上下文压缩方案**，在保障长线编程任务上下文连贯性的同时，显著压缩多轮会话的推理成本。
 4. 设计**自动记忆提取**方法，自动提取用户偏好、纠正反馈、项目知识、参考信息四类记忆持久化到文件，实现**跨会话长期记忆累积**，同类错误纠正一次后自动规避，新对话自动继承。
 5. 构建**五层操作权限安全网**，利用**事件驱动的 Hook 机制**实现高危系统调用的兜底拦截，确保 Agent 在全自动模式下的绝对安全执行。
 6. 实现**多 Agent 协作**，将任务拆分给多个 Agent 并行处理，并基于 Git Worktree 打造文件级隔离避免编辑冲突。突破单 Agent 上下文窗口瓶颈，提升大型任务处理效率。