


韩玲简历

求职意向：大模型算法工程师、数字人



出生：1991.08

电话：17710782178

民族：汉

邮箱：hlingly@163.com

教育背景

山东大学

2015.09-2018.07

运筹学与控制论 - 硕士

曲阜师范大学

2010.09-2014.07

统计学 - 学士

专业技能

- 熟悉 ChatGLM 系列, GPT2, Qwen 系列,llama 系列等大模型的部署与应用
- 熟悉使用 Langchain、Langgraph 框架用大模型构建应用程序和节点, RAG 检索增强优化技术进行知识库问答
- 熟悉使用 vllm,xinference,ollama 一些推理框架为模型进行加速推理
- 熟练使用 TensorFlow、PyTorch 等深度学习框架进行模型开发与训练, 熟悉自然语言处理基本任务, 例如文本分类、对话生成、知识图谱、NER 命名实体识别
- 熟悉模型的微调, 根据业务需求对预训练模型进行定制化开发, 提升模型性能
- 熟悉嘴型驱动模型 MuseTalk、MuseV、wav2lip, 文生图、图生视频技术

工作经历

2024.03 ~ 至今

浪潮智慧城市科技有限公司

大模型算法工程师

2021.08 ~ 2023.09

联想

智能数据主管研究员

2020.11 ~ 2021.06

快手

策略算法工程师

2018.07 ~ 2020.10

金瓜子科技有限公司

算法工程师

项目经验

智能问答系统优化

主要负责项目中间答场景的优化, 针对用户的场景有针对性的做知识库、模型的优化

- * 基于 xinference 做模型的部署, 包括大语言模型、embedding 模型、rerank 模型
- * 基于 langchain 框架, 做 RAG 检索增强的优化, 包括: prompt 提示词优化、不同文件的处理、切分方式、embedding 模型的选择、召回方式的选择、召回的重排序等优化
- * 构建知识库: 根据业务场景构造不同的知识库, 包括 ES 知识库、向量知识库、知识图谱等
- * 基于业务数据做 lora 微调, 构造微调数据

* 基于 GRPO 训练基于业务场景的推理模型

智能问数系统搭建优化

背景：执法部门需要定期提交执法画像分析报告，全面反映执法运行态势、质效与风险。过去依赖人工逐表统计、多系统取数、手工计算汇总，效率低、时效差、准确性难以保障。目前升级为“自然语言问数 + 智能报告自动生成”模式，实现从数据查询到可视化分析报告的一站式产出，大幅提升执法管理的数据支撑能力和决策效率。

问数方法：构建基于 LangGraph 的问数智能体流程：先将复杂问题拆解为原子取数任务，通过 RAG 检索相关 schema 与指标规则生成 DSL，调用 SQL 接口执行查询，并在 merge 阶段使用确定性计算模块完成合计与同比等指标计算。通过配置业务场景规则及相关业务指标，减少大模型幻觉与算错问题，提升稳定性与可解释性。

写作方法：基于多智能体构建：数据分析智能体、大纲解析智能体、文档生成智能体 形成结构完整、逻辑清晰、内容规范的执法画像分析报告，为执法监督与管理提供一站式、可复用、智能化的画像支撑服务。

效果：问数准确率达到 95%， 用户画像报告生成从人工数天缩短至模型数小时

热点分析报告生成：

背景：对于 12345 投诉工单，针对已办理案件，每月需要分地区统计举报违停点位数， 诉求多发区域研判靠半人工统计，效率低，失误率高，精度无法得到保障，平均 2 人耗时 2 天才能完成一份报告

技术：采用大模型提取 12345 投诉工单的地址， 再采用两阶段法实现投诉地点的准确统计。一阶段：采用“BallTree 加速 + 余弦距离阈值 $\cos_dis$ 来实现簇内任意两点余弦距离 $\leq \cos_dis$ ”的严格直径约束聚类。

贪心扩展 + BallTree 候选过滤 + 严格直径检查避免普通聚类的两点最远距离扩展问题

二阶段：采用大模型对上述找出来的同类别的地点的核心地点提取出来，实现分布的精确扩展

效果：高发区域识别精度提升：热点区域识别准确率提升至 85%以上，覆盖 90%高频诉求点，民警重点巡查范围缩减 60%，效率倍增。民意报告优化提升：民意分析报告生成从人工数天缩短至模型数小时

一事多人：

背景：12345 政务服务便民热线是当前中国城市治理中最主要的民意入口和诉求响应渠道。其中重复性、关联性极强的群体诉求占比显著上升，已成为影响热线整体效率、群众满意度和基层治理闭环的最突出问题之一。项目本质是解决“同一件事被表述成千百种样子，却无法被系统感知为同一件事”这个核心矛盾

技术：采用大模型驱动的闭环自进化体系构建政务工单分类。冷启动阶段：用少量人工标注+大模型生成种子分类体系。日常阶段：监控低置信度工单，聚类提取盲区代表样本，再由大模型分析共性、提出新类别名称/定义/关键词，补充体系。形成“使用→发现盲区→自动生成新类→升级→准确率提升”的自优化闭环，持续降低人工干预，提高长尾诉求覆盖率与分类精度

效果：系统实时监控高频分类与重复诉求，自动预警群体性事件，分钟级发现苗头问题。大模型对新工单进行精准意图判别，提供最匹配类别、置信度及理由

数字人

基于大屏和小程序研究了两套数字人模型，基于音频驱动口型、声音克隆、文生图、图生视频等技术实现了数字人的形象定制、声音克隆、背景替换等服务

* 基于文生图、图生视频技术、自定义视频等方式定制化生成数字人数据集

* 基于 MuseTalk、Wav2lib 等嘴型模型实现真人化效果

* 基于 cosyvoice、gptsovits 等 tts 模型实现语音定制化服务

* 接入大语言模型实现对话式数字人交互

psd (promising shipment date)

- * 项目背景： 用户下单后未收货前，每天都会看到自己订单的预计发货时间， 如果每天看到的预计发货时间一直频繁更新变化， 会给客户带来不好的体验
- * 方案： 运用机器学习的方式来给出一个比较稳定的发货时间
- * 效果： AUC: 89%; 业务指标 ≤ 1 次的指标 提升 20%， 并且获得了联想研究院的项目奖

营销券相关风控模型

- * 方案： 利用机器学习的方式， 迭代更新相关的风控策略， 识别各类机器行为、羊毛党等欺诈行为
- * 效果： 漏过降低 12%

员工及家属识别

- * 方案： 利用 wifi、ip、通讯录等方式挖掘相关的员工、员工家属及联系人
- * 效果： 准确率高达 95%、召回高达 90%